

Các Mô hình Ngôn ngữ Lớn là những Người phòng thủ mạng tự động

Sebastián R. Castro, Roberto Campbell, Nancy Lau, Octavio Villalobos, Jiaqi Duan, Álvaro A. Cárdenas
University of California, Santa Cruz

Tóm tắt nội dung—Phản ứng sự cố (incident response) nhanh và hiệu quả là điều thiết yếu để ngăn chặn các cuộc tấn công mạng (cyberattack) đôi kháng. Phòng thủ mạng tự động (ACD — Autonomous Cyber Defense) hướng tới việc tự động hóa phản ứng sự cố thông qua các tác nhân (agent) Trí tuệ nhân tạo (AI) có khả năng lập kế hoạch và thực thi hành động. Hầu hết các cách tiếp cận ACD tập trung vào kịch bản đơn tác nhân (single-agent) và tận dụng Học tăng cường (RL — Reinforcement Learning). Tuy nhiên, các tác nhân ACD được huấn luyện bằng RL phụ thuộc vào quá trình huấn luyện tốn kém, và suy luận của chúng không phải lúc nào cũng giải thích được (explainable) hoặc chuyển giao được (transferable). Các Mô hình Ngôn ngữ Lớn (LLM — Large Language Model) có thể giải quyết những lo ngại này bằng cách cung cấp các hành động có thể giải thích trong những ngữ cảnh an ninh tổng quát. Các nhà nghiên cứu đã khám phá tác nhân LLM cho ACD nhưng chưa đánh giá chúng trong các kịch bản đa tác nhân (multi-agent) hay khi tương tác với các tác nhân ACD khác. Trong bài báo này, chúng tôi trình bày nghiên cứu đầu tiên về cách LLM hoạt động trong các môi trường ACD đa tác nhân, bằng cách đề xuất một tích hợp mới vào môi trường Cyborg CAGE 4. Chúng tôi xem xét cách các đội (team) ACD gồm tác nhân LLM và RL có thể tương tác với nhau, bằng cách đề xuất một giao thức truyền thông (communication protocol) mới. Kết quả của chúng tôi làm nổi bật các điểm mạnh và điểm yếu của LLM và RL, đồng thời giúp chúng tôi xác định những hướng nghiên cứu hứa hẹn để tạo ra, huấn luyện và triển khai các đội tác nhân ACD trong tương lai.

Index Terms—Autonomous Cyber Defense (Phòng thủ mạng tự động), Incident Response (Phản ứng sự cố), Large Language Models (Mô hình ngôn ngữ lớn), Reinforcement Learning (Học tăng cường), AI Agents (Tác nhân AI).

I. GIỚI THIỆU

Các mối đe dọa mạng (cyber threats) đang phát triển nhanh chóng, ngày càng phức tạp, thường xuyên và tốn kém hơn đối với các tổ chức. Một báo cáo của Checkpoint cho thấy các cuộc tấn công đang ở mức cao nhất mọi thời đại, với số cuộc tấn công mạng trung bình hàng tuần trên mỗi tổ chức là 1800, so với 800 ở quý III năm 2024 [1].

Theo cách truyền thống, việc phản ứng trước các cảnh báo xâm nhập (intrusion alerts) đòi hỏi những người vận hành (operator) là chuyên gia con người để phân tích sự cố và phục hồi sau tấn công. Khi mức độ tinh vi của các cuộc tấn công mạng tăng lên [2], việc quản lý thủ công các phản ứng an ninh ngày càng trở nên thách thức. Để giải quyết vấn đề này, cần có tự động hóa không chỉ để phát hiện mà còn để phản ứng trước các cuộc tấn công theo thời gian thực (real-time). Phòng thủ mạng tự động (ACD) tiếp cận điều này bằng cách dùng các tác nhân AI để phát hiện và giảm thiểu (mitigate) các cuộc tấn công.

Các tác nhân ACD chủ yếu dựa trên Học tăng cường (RL). Tuy vậy, việc áp dụng chúng vào các hệ thống thực tế bị ràng buộc bởi (1) khả năng giải thích hạn chế (limited explainability), (2) khả năng chuyển giao hạn chế sang các môi trường khác (kể tấn công khác hoặc mạng khác), và (3) các thách thức huấn luyện do việc tạo ra môi trường thực tế phức tạp và sự kém hiệu quả về mẫu (sample inefficiency) của RL [3].

Để giải quyết những hạn chế của các cách tiếp cận dựa trên RL, chúng tôi nghiên cứu liệu các tiến bộ trong LLM có thể tạo ra đột phá (disrupt) hay không. Thứ nhất, LLM có thể cung cấp lời giải thích cho các quyết định của chúng. Thứ hai, chúng đã được huấn luyện với dữ liệu từ nhiều mô hình mối đe dọa (threat models) và mạng đa dạng. Thứ ba, chúng ta có thể dùng các mô hình đã huấn luyện trước (pre-trained models) mà không cần phát triển một môi trường gym.

Trước khi tác nhân LLM có thể được dùng cho ACD, chúng ta cần trả lời một số câu hỏi nghiên cứu, bao gồm: Làm thế nào để huấn luyện, thiết kế và triển khai các đội tác nhân ACD? LLM hoạt động như tác nhân ACD ra sao so với tác nhân RL? LLM có thể giải quyết những hạn chế của RL cho ACD bằng cách cung cấp một lối suy luận thực tiễn, con người có thể diễn giải được (human-interpretable) về chiến lược của tác nhân hay không? Tác nhân ACD dùng LLM có thể đưa ra những quyết định hợp lý và tổng quát hóa (generalize) trước các đối thủ khác nhau hay không? LLM phải giải quyết những thách thức nào để hướng tới ACD?

Để trả lời những câu hỏi này, chúng tôi đề xuất các đóng góp sau:

- 1) **Khung LLM+RL cho ACD:** Chúng tôi phát triển nghiên cứu đầu tiên về cách LLM hoạt động trong các môi trường ACD đa tác nhân, bằng cách tạo ra một khung (framework) để tích hợp LLM vào Cyborg [4], môi trường mô phỏng nổi bật nhất cho ACD và RL. Chúng tôi công khai mã nguồn (open source) khung này.¹
- 2) **Giao thức truyền thông đa tác nhân cho ACD:** Chúng tôi giới thiệu và đánh giá giao thức truyền thông đầu tiên cho các tác nhân ACD đa dạng (RL và LLM) trong các thí nghiệm của mình.
- 3) **Đánh giá:** Chúng tôi đánh giá các tác nhân RL và LLM trước một tập đối thủ đa dạng, thảo luận về các ưu thế của LLM so với RL để cải thiện tác nhân ACD. Chúng tôi xác định những hướng hứa hẹn cho nghiên cứu tương

¹<https://github.com/r4wd3r/llms-are-acd>


lai, bao gồm tinh chỉnh mô hình và prompt (model and prompt tuning), và lập kế hoạch dựa trên mục tiêu (goal-based planning).

II. BỐI CẢNH

ACD tập trung vào việc tạo ra các tác nhân AI có thể phản ứng trước sự cố một cách nhanh và chính xác [5],[6]. Thông thường, các tác nhân này được huấn luyện trong những môi trường mô phỏng gọi là *ACD gyms* (sân tập ACD). Các gym này cung cấp một bộ thử nghiệm (testbed) tái tạo một mạng mô phỏng, nơi các tác nhân tương tác với môi trường và học cách phòng thủ trước những kẻ tấn công [7]. Các gym được thiết kế tốt cung cấp nhiều loại kịch bản để khám phá hiệu quả các không gian trạng thái (state spaces) [8], đảm bảo tính vững chắc (robustness), và mô phỏng các kịch bản thực tế [7],[9]. Các ví dụ về gym bao gồm CyberBattleSim [10], NASimEmu [11], và FARLAND [12]. Tuy nhiên, các khung này không phải tất cả đều truy cập công khai được, được bảo trì tích cực, hoặc bị giới hạn ở những kịch bản đối kháng cụ thể.

Một trong những môi trường ACD liên quan nhất là CyBORG [4], nền tảng cho các CAGE Challenges [13]. CyBORG cung cấp một mức trừu tượng cao (high-level abstraction) cho nhiều kịch bản mô phỏng đối thủ (adversary emulation) đa dạng (ví dụ: mạng drone và mạng doanh nghiệp). CAGE Challenge là một cuộc thi thường niên của Chương trình Hợp tác Kỹ thuật (TTCP — Technical Cooperation Program) nhằm thúc đẩy trình độ tân tiến nhất (state-of-the-art) của ACD. Dùng gym CyBORG, người tham gia thử thách này nộp các tác nhân phòng thủ (blue agents — tác nhân xanh) để loại bỏ những kẻ tấn công (red agents — tác nhân đỏ) và tối đa hóa tính khả dụng (availability) cho người dùng mạng trong khi bảo vệ các dịch vụ trọng yếu.

Các CAGE challenge đánh giá phần dự thi của cộng đồng dựa trên phần thưởng chung (joint reward) cao nhất đạt được trong các mô phỏng. Các phần dự thi trước đây cho CAGE challenge dùng tác nhân RL. Phiên bản mới nhất, CAGE 4 Challenge, bao gồm một môi trường đa tác nhân với truyền thông hạn chế giữa các tác nhân phòng thủ, khả năng quan sát mạng một phần (partial network observability), và một phần thưởng được chia sẻ (shared reward) giữa các tác nhân. Trong một phần dự thi cho thử thách này, Singh và cộng sự [14] đề xuất một cách tiếp cận RL phân cấp (hierarchical RL) bằng cách phân rã không gian hành động thành một meta-policy (chính sách cấp cao) và ba sub-policy (chính sách con). Kết quả của họ cho thấy một meta-policy chuyên gia mạnh có thể vượt trội hơn một chính sách Tối ưu hóa Chính sách Cận kề (PPO — Proximal Policy Optimization) chung [15]. Trong một phần dự thi khác, đội Cybermoniac đề xuất KEEP, một biến thể của PPO với Mạng tích chập đồ thị (GCN — Graph Convolutional Networks) [16]. KEEP cấu trúc các quan sát thành các đồ thị không đồng nhất (heterogeneous graphs) của các thực thể (ví dụ: tệp tin, máy chủ, router và cổng), nơi các hành động của tác nhân làm thay đổi các đồ thị này. Tại thời điểm viết bài, KEEP của Cybermoniac là lời giải mã nguồn mở duy nhất trên bảng xếp hạng (leaderboard) của cuộc thi



Hình 1. Kiến trúc của CAGE 4 Challenge.

Bảng I
DANH SÁCH CÁC HÀNH ĐỘNG THEO TỪNG TÁC NHÂN.

Blue (Xanh)	Red (Đỏ)	Green (Lục)
Monitor	Discover	LocalWork
Analyse	Exploit	AccessService
DeployDecoy	PrivilegeEscalate	
Remove	DegradeService	
Restore	Impact	
AllowTrafficZone/ BlockTrafficZone	Withdraw	

CAGE 4. Do đó, chúng tôi dùng nó làm đường cơ sở (baseline) cho các đánh giá của mình.

Công trình gần đây cũng đã bắt đầu khám phá các tác nhân LLM cho ACD. Rigaki và cộng sự [17] đề xuất một kẻ tấn công kiểu ReACT dựa trên LLM cho môi trường NetSecGame, và Yan và cộng sự [18] đề xuất một tác nhân RL được huấn luyện kiểu mã nguồn đóng (closed-source), cung cấp phản hồi hành động cho một LLM được triển khai cho thử thách CAGE 1. Tuy nhiên, các cách tiếp cận này chỉ được triển khai trong các mô phỏng đơn tác nhân và chưa khám phá việc ra quyết định của LLM so với RL. Trong bài báo này, chúng tôi giới thiệu tích hợp đầu tiên của cả tác nhân LLM lẫn RL trên thử thách đa tác nhân CAGE 4, và đề xuất các cách tiếp cận để phân tích suy luận của LLM cho việc chọn hành động (action selection). Chúng tôi cho rằng những bước này sẽ đưa chúng ta tới gần hơn việc hiểu cách AI sinh tạo (generative AI) có thể giúp thiết kế các tác nhân ACD tương lai cho phản ứng sự cố thực tế.

A. CyBORG CAGE 4

CAGE 4 Challenge mô phỏng một kịch bản Học tăng cường đa tác nhân (MARL — Multi-Agent Reinforcement Learning) với một đội tác nhân phòng thủ (*blue agents*) bảo vệ một mạng khỏi những kẻ địch (*red agents*) trong khi duy trì tính khả dụng dịch vụ cho người dùng (*green agents*). Như thấy trong Hình 1, mạng được chia thành các vùng (zones) được các blue agent bảo vệ như sau: hai mạng triển khai (deployed networks A và B), mỗi mạng chứa các vùng bị hạn chế (restricted) và vùng vận hành (operational); một mạng trụ sở (headquarters) với vùng truy cập công cộng, vùng quản trị và vùng văn phòng; và một mạng nhà thầu (contractor network) nơi red agent khởi đầu. Các green agent có thể dùng tất cả hệ thống trong mạng, nhưng chúng có một xác suất nhỏ trao quyền truy cập một

máy chủ ngẫu nhiên cho red agent do trở thành nạn nhân của một “tấn công lừa đảo” (phishing attack). Mỗi tác nhân có một tập hành động được định nghĩa trong Bảng I. CAGE 4 diễn ra qua 3 pha (Planning — Lập kế hoạch, Mission A — Nhiệm vụ A, Mission B — Nhiệm vụ B), mỗi pha có các ràng buộc truyền thông khác nhau giữa các vùng mạng. Các vùng vận hành cụ thể trở nên bị cô lập (isolated) trong các nhiệm vụ đang hoạt động, trong khi các vùng bị hạn chế có kết nối giới hạn. Các blue agent phải thích ứng chiến lược của mình theo các chính sách (policy) thay đổi, chẳng hạn như chặn các kết nối trái phép trong khi đảm bảo các dịch vụ trọng yếu vẫn khả dụng cho người dùng hợp pháp (green agents).

Hàm thưởng (reward function) cho các *blue agent* được thiết kế để nhận hình phạt (penalty) nếu các green agent không thể dùng tài nguyên. Điều này có thể xảy ra do các hành động phòng thủ như chặn một mạng hoặc khôi phục (restore) một máy chủ (việc này tạm thời đưa máy chủ ra khỏi hoạt động một thời gian), hoặc khi các red agent gây tác động (impact) lên hệ thống của chúng.

III. TÁC NHÂN LLM CHO PHÒNG THỦ MẠNG TỰ ĐỘNG

Chúng tôi đã tạo ra một tác nhân dựa trên LLM cho CybORG CAGE 4 [4]. Theo hiểu biết của chúng tôi, đây là triển khai đa tác nhân đầu tiên của một LLM tương tác với các loại tác nhân ACD khác, bao gồm cả tác nhân RL. Trong phần này, chúng tôi thảo luận về các thách thức và thiết kế của mình.

A. Khung Bộ điều hợp LLM (LLM Adapter Framework)

Để hiểu cách LLM hoạt động như tác nhân ACD trong các kịch bản mô phỏng/giả lập (simulated/emulated), chúng tôi tạo ra một khung bộ điều hợp (adapter framework) có khả năng mở rộng để tích hợp LLM vào CybORG. Việc phát triển nó đặt ra các thách thức về tối ưu hóa hiệu năng và chi phí. Trong pha kiểm thử của mình, CybORG được thiết kế để chạy với các chính sách RL hậu huấn luyện (offline post-training RL policies). Do đó, việc chọn hành động nhanh hơn đáng kể so với thời gian suy luận (inference time) của LLM. Trong các thí nghiệm của chúng tôi, suy luận LLM để chọn hành động với một mô hình nhỏ trực tuyến (tức là GPT-4o-mini [19]) trung bình chậm hơn **150 lần** so với việc chọn hành động qua một chính sách RL hậu huấn luyện. Để khắc phục điều này, khi phát triển các phiên bản ban đầu của bộ điều hợp, chúng tôi dựa vào các mô hình ngoại tuyến nhẹ (ví dụ: TinyLLaMA) và các tối ưu hóa GPU, loại bỏ chi phí cho các mô hình trả phí cùng phần phụ trội (overhead) do độ trễ mạng (network latency) và thời gian suy luận.

Hình 2 thể hiện bộ điều hợp LLM của chúng tôi và quy trình làm việc (workflow) của nó cho việc chọn hành động bằng các mô hình này. Chúng tôi làm nổi bật bộ điều hợp LLM và cách nó tương tác với các tác nhân khi mô phỏng CAGE 4 bắt đầu. Hình thể hiện kịch bản trong đó một blue agent do LLM điều khiển (LLM-driven) và các tác nhân còn lại do RL điều khiển (RL-driven). Như đã thể hiện, chúng tôi thêm các chính sách tùy chỉnh (custom policies) cho cả red và blue agent, chúng tôi đưa vào một chính sách RL dựa trên

Bảng II
QUAN SÁT ĐÃ ĐỊNH DẠNG CHO TÁC NHÂN LLM.

Field (Trường)	Value (Giá trị)
Agent	<agent_name>
Mission Phase	<value>
Last Action	<action><host/subnet>
Last Action Status	<TRUE/FALSE/UNKNOWN/IN_PROGRESS>
Communication Vectors	<list:binary_array>
Suspicious Activity Detected	<list:string>

KEEP GNN để huấn luyện và kiểm thử [16], chúng tôi thêm một giao thức truyền thông mới cho các blue agent, và đề xuất một bộ điều hợp LLM linh hoạt để tương tác với các LLM đa dạng cho việc chọn hành động.

B. Định dạng Quan sát và Phản hồi

Trạng thái mạng phải được định dạng bằng ngôn ngữ tự nhiên (natural language) để dùng một LLM cho phòng thủ mạng. Vì CybORG được thiết kế cho RL, nó dùng các vectơ quan sát (observation vectors) mà con người không đọc được. Để khắc phục tình huống này, chúng tôi xây dựng một lớp bao bọc (wrapper) tùy chỉnh nhằm điều chỉnh các quan sát theo bước (step observations) của CybORG bằng cách phân tích cú pháp (parse) chúng thành ngôn ngữ tự nhiên với thông tin liên quan mà mỗi tác nhân thấy về mạng của mình.


Bảng II thể hiện định dạng quan sát của chúng tôi theo từng bước, bao gồm tên của tác nhân (Agent), pha nhiệm vụ (Mission Phase), hành động cuối cùng (Last Action) đã thực thi ở các bước trước cùng kết quả trạng thái (Status) của nó, các vectơ truyền thông (Communication Vectors) được các blue agent quảng bá (broadcast), và một danh sách sự kiện trong mục hoạt động đáng ngờ được phát hiện (Suspicious Activity Detected).

Để trích xuất các hành động của blue agent, chúng tôi định dạng phản hồi của LLM bằng một cấu trúc từ điển (dictionary) như thấy trong Hình 3. Nếu LLM trả lời theo một định dạng không mong đợi mà bộ phân tích hành động (action parser) của chúng tôi không hiểu, chúng tôi ghi nhận một hành động không hợp lệ (invalid action), và tác nhân sẽ *Sleep* (ngủ — không hành động) trong bước đó. Điều này giúp chúng tôi theo dõi khi mô hình không tuân theo cấu trúc phản hồi mà chúng tôi cung cấp trong prompt.

C. Giao thức truyền thông giữa các Tác nhân phòng thủ

Vì các blue agent chỉ có khả năng quan sát trong mạng con (subnet) được phân công của mình (xem Hình 1), chúng cần trao đổi thông điệp với nhau để chia sẻ thông tin mỗi đe dọa. CAGE 4 cho phép mỗi tác nhân quảng bá một vectơ 1 byte mỗi bước, gọi là *Communication Vector* (Vectơ truyền thông), nhưng định dạng của nó chưa được định nghĩa. Chúng tôi dùng giao thức 8-bit này và đề xuất một chiến lược truyền thông đa tác nhân thực tế.

Ý tưởng của chúng tôi là tóm tắt mức an ninh hiện tại của một mạng dựa trên quan sát của mỗi tác nhân và trạng thái hiện tại của nó (rảnh hay bận — free or busy). Điều này trừu tượng hóa trạng thái tổng quát của mạng mà không làm tăng



Hình 2. Tổng quan về Khung Bộ điều hợp LLM của chúng tôi.

đáng kể số chiều của quan sát. Chúng tôi đề xuất rằng mỗi tác nhân nên quảng bá một thông điệp tới các tác nhân khác để thông báo cho chúng về (1) hoạt động đáng ngờ được phát hiện từ mạng của một tác nhân khác, (2) mức an ninh của mạng hiện tại của nó, và (3) tính sẵn sàng (availability) của nó để chạy hành động.

Đối với việc phát hiện hoạt động từ xa (1), chúng tôi gán cho mỗi tác nhân một bit duy nhất, vì mỗi tác nhân chỉ có thể truy cập quan sát của riêng mình nhưng có thể liên hệ nguồn gốc của các hoạt động độc hại từ các mạng khác. Đối với mức an ninh hiện tại (2), chúng tôi cung cấp độ chi tiết cao hơn bằng cách gán 2 bit, vì quan sát của tác nhân chứa nhiều chiều hơn mô tả trạng thái an ninh mạng chi tiết hơn. Chúng tôi chỉ gán một bit cho tính sẵn sàng (3) vì tác nhân chỉ có thể ở trạng thái rảnh hoặc bận.

Xét rằng các tác nhân phòng thủ được định danh từ 0 đến 4, mỗi blue agent i trong mạng tạo ra Communication Vector của mình như sau:

- **Bit 0 đến 4:** Đặt bit j bằng một nếu i phát hiện một hành động độc hại từ mạng của tác nhân j . Ngược lại, bằng không.
- **Bit 5 và 6:** Mức xâm phạm (level of compromise) mà tác nhân i nhận diện trong mạng con của mình: 00 không có xâm phạm, 01 phát hiện netscan/khai thác từ xa (remote exploit), 10 xâm phạm cấp người dùng (user-level) trong một máy chủ, 11 xâm phạm cấp quản trị (admin-level) trong một máy chủ.
- **Bit 7:** Đặt bằng một nếu tác nhân i đang chờ một hành động hoàn tất thực thi. Ngược lại bằng 0.

Giao thức này có thể được mở rộng thành các bản tóm tắt chi tiết hơn tùy theo dung lượng và các đặc trưng quan sát. Chúng tôi tin rằng cách tiếp cận này cung cấp đủ thông tin cho các tác nhân để cải thiện quá trình chọn hành động của chúng, đặc biệt khi các tác nhân thông báo một mức an ninh rủi ro cao và các tác nhân khác phát hiện kết nối từ mạng của chúng.

Bảng III
TÍNH CHỈNH PROMPT DỰA TRÊN PHẦN THƯỞNG VỚI CÁC MÔ HÌNH OPENAI. KẾT QUẢ LÀ PHẦN THƯỞNG TRUNG BÌNH CHO BLUE AGENT.


Model	Role	Few-shot	Instruct
GPT-3.5 Turbo	-4307	-4349,5	-4620
4o-mini	-3810	-3219	-2888
o1-mini	-3022	-3243,5	-3890,5

D. Thiết kế Prompt (Prompting)

Chúng tôi hướng tới việc đánh giá cách LLM hành động và suy luận trong các tình huống phản ứng sự cố thực tế, thay vì tối đa hóa hàm thưởng của CAGE 4. Do đó, chúng tôi thiết kế các prompt mang lại cho LLM một góc nhìn thực tế về một mạng và tránh đề cập rằng đây là một trò chơi, một mô phỏng, hay có một hàm thưởng. Thay vào đó, chúng tôi gán cho tác nhân vai trò (role) một “chuyên gia an ninh mạng đang phòng thủ một mạng” với các quy tắc định dạng và ví dụ để dẫn dắt quá trình suy luận. Prompt chi tiết nằm trong kho mã (repository) của chúng tôi.

Để đánh giá chiến lược prompting tốt nhất vừa thực tế vừa giảm thiểu hình phạt, chúng tôi dùng một red agent kiểu Máy trạng thái hữu hạn (Finite State) mặc định của CAGE 4, đặt chỉ một blue agent là tác nhân do LLM điều khiển và phần còn lại theo chiến lược phòng thủ mặc định của CAGE 4. Chúng tôi bắt đầu với Prompting kiểu Hướng dẫn (Instructional Prompting) ban đầu [20], nơi chúng tôi chỉ mô tả nhiệm vụ và định dạng câu trả lời. Sau đó, chúng tôi xét chiến lược Few-Shot (vài ví dụ mẫu), nơi, bên cạnh mô tả nhiệm vụ, chúng tôi thêm các ví dụ về câu trả lời đúng khả dĩ, điều này làm giảm các hành động không hợp lệ. Cuối cùng, chúng tôi khám phá Role Prompting (prompt theo vai trò) [21] bằng cách gán vai trò “chuyên gia an ninh mạng” cho tác nhân.

Như thấy trong Bảng III, trung bình, việc thêm một vai trò vào prompt cùng với các ví dụ few-shot có thể làm tăng phần thưởng qua các thí nghiệm khác nhau. Do đó, chúng tôi quyết định dùng một prompt có vai trò và các ví dụ few-shot.



Hình 3. Quy trình hội thoại (conversation workflow) cho Bộ điều hợp LLM.

Hình 3 thể hiện tổng quan về tương tác giữa tác nhân và LLM. Chúng tôi tuân theo các quy ước về nhấn tin kiểu system/developer (hệ thống/nhà phát triển) và user (người dùng) cho LLM [19],[22],[23]. Chúng tôi đặt System Prompt để mô tả nhiệm vụ, xác thực phản hồi (response validation), các quy tắc môi trường, và các ví dụ. User Prompt chứa quan sát đã định dạng theo từng bước. Lưu ý rằng System Prompt giữ nguyên nhất quán trong suốt tất cả các episode (lượt chơi/tập), trong khi User Prompt có thể thay đổi do quan sát của tác nhân.

Chúng tôi đã tinh chỉnh prompt để bao gồm các định nghĩa rõ ràng và súc tích cho mỗi hành động, kèm theo ví dụ phản hồi. Điều này là cần thiết vì tên hành động có thể mang nhiều nghĩa, điều có thể làm sai lệch các mô hình suy luận. Chẳng hạn, khi chúng tôi không định nghĩa hành động *Remove* trong các thí nghiệm, LLM giả định rằng nó ngắt kết nối máy chủ thay vì xóa các tiến trình độc hại.

Bộ điều hợp CybORG có khả năng mở rộng của chúng tôi cho LLM hoạt động với các mô hình trực tuyến và ngoại tuyến mới nhất. Đối với các phiên bản trực tuyến, bộ điều hợp hiện tại của chúng tôi hỗ trợ OpenAI [19] và DeepSeek [22] thông qua OpenRouter [24]. Đối với các mô hình ngoại tuyến, nó hỗ trợ các mô hình mã nguồn mở từ HuggingFace [25], bao gồm họ mô hình LLaMA [23] của Meta.

IV. ĐÁNH GIÁ

Trong phần này, chúng tôi mô tả các thí nghiệm và kết quả của chúng. Trước tiên chúng tôi mô tả phương pháp luận và các cân nhắc cho việc thiết lập môi trường. Sau đó, chúng tôi thảo luận chi tiết các kết quả thí nghiệm và phân tích của mình.

Môi trường và mô hình: Chúng tôi dùng phiên bản CybORG có trong kho lưu trữ thử thách CAGE 4 [13] bao gồm bộ điều hợp LLM tùy chỉnh của mình. Chúng tôi dùng các mô hình OpenAI mới nhất [19] GPT-4o-mini, o1-mini và o3-mini, và mô hình DeepSeek mới nhất: DeepSeek-V3 [22]. Khi chạy các thí nghiệm, chúng tôi tập trung vào các mô hình nhẹ để giảm thời gian suy luận và phân phụ trội hiệu năng. Với

tất cả mô hình, chúng tôi đặt temperature (nhiệt độ — tham số kiểm soát độ ngẫu nhiên) bằng 1 để tránh các hạn chế về sự phụ thuộc ngữ cảnh từ prompt, vì prompt được chú ý không tối ưu hóa riêng cho kịch bản CAGE 4. Để theo dõi các biến số thí nghiệm, bao gồm phần thưởng, độ lệch chuẩn, và việc chọn hành động, chúng tôi dùng nền tảng Wandb (Weights and Biases) [26].


Nhấn tin với LLM (LLM Messaging): Vì CybORG chạy hàng trăm bước mỗi episode, và mỗi tác nhân phải chọn một hành động mỗi bước, chúng tôi dùng một thông điệp system/user duy nhất để tương tác với LLM nhằm giảm tiêu thụ token. Như thấy trong Hình 3, chúng tôi dùng một system prompt chứa nhiệm vụ cần chạy. Sau đó chúng tôi đưa vào quan sát của bước hiện tại dưới dạng một user message. Các tác nhân do LLM điều khiển gửi một tổ hợp của hai thông điệp này mỗi bước và nhận một phản hồi ở định dạng JSON chứa một hành động và một lý do (reason) biện minh cho quyết định của nó.

Các kịch bản: Với tất cả thí nghiệm, chúng tôi chạy 2 episode của trò chơi, mỗi episode 500 bước. Mỗi tác nhân (red, blue và green) chọn một hành động trong mỗi bước, và CybORG mô phỏng việc thực thi nó. Chúng tôi dùng chính sách green agent mặc định của CybORG là *EnterpriseGreenAgent* trong khi tùy chỉnh red và blue. Trong các thí nghiệm, chúng tôi xét bốn kịch bản cho blue agent:

- **Không có blue agent:** Tất cả blue agent đều *Sleep* mỗi lượt. Chỉ red và green agent hành động. Đây là đường cơ sở (baseline) cho đánh giá của chúng tôi.
- **Tất cả blue agent là LLM:** Tất cả blue agent đều do LLM điều khiển. Tất cả dùng cùng một LLM và cùng chiến lược nhấn tin với cùng system prompt. User message của chúng có thể thay đổi theo quan sát của mỗi tác nhân và bao gồm tên tác nhân để tránh làm LLM nhầm lẫn.
- **Tất cả blue agent là RL:** Tất cả blue agent đều dựa trên RL. Chúng tôi huấn luyện chúng bằng cách dùng hiện thực Communication Vector của riêng mình và mô hình KEEP GNN PPO của Cybermonics [16], vốn nằm trong số các phần dự thi tốt nhất cho cuộc thi CAGE 4 [13]. Phần dự thi này không hiện thực Communication Vector.
- **1 blue agent LLM và 4 blue agent RL:** Để cân bằng phân bố RL và LLM, chúng tôi bảo vệ 3 mạng con bằng 1 tác nhân LLM (tức là blue agent 4) và 4 mạng con bằng 4 tác nhân RL (KEEP).

Các biến thể red agent: CybORG bao gồm các red agent kiểu máy trạng thái hữu hạn (finite-state), có giới hạn. Để giảm khoảng cách so với thực tế (reality gap) và đa dạng hóa mô phỏng đối thủ, chúng tôi hiện thực các chiến lược red agent cho học tăng cường đa tác nhân của Singh và cộng sự [14]. Cụ thể, chúng tôi bao gồm những loại sau:

- **AggressiveFSMAgent:** Sử dụng hành động dò tìm dịch vụ (service discovery) hung hãn, quét mạng nhanh để nhận diện các mục tiêu tiềm năng. Dù cách tiếp cận này có thể nhanh chóng lập bản đồ các dịch vụ mạng, nó làm tăng khả năng bị các biện pháp phòng thủ phát hiện.



Hình 4. Phần thưởng và thời gian chạy theo từng mô hình. 1 blue agent do LLM điều khiển và các tác nhân khác do RL, đối đầu với red agent FiniteState mặc định.


- **StealthyFSMAgent:** Sử dụng các hành động dò tìm dịch vụ lén lút (stealthy), nhằm giữ không bị phát hiện trong khi thu thập thông tin về mạng. Phương pháp này chậm hơn nhưng giảm rủi ro kích hoạt các cảnh báo an ninh.
- **ImpactFSMAgent:** Ưu tiên hành động gây tác động lên các dịch vụ trọng yếu, tập trung phá vỡ các chức năng mạng thiết yếu. Bằng cách nhắm vào các tài sản giá trị cao, ImpactFSMAgent hướng tới tối đa hóa sự gián đoạn vận hành.
- **DegradeServiceFSMAgent:** Ưu tiên hành động làm suy giảm (degrade) các dịch vụ mà green agent sử dụng. Điều này có thể khiến hành động *GreenAccessService* thất bại.

A. Các thí nghiệm

Giờ chúng tôi thảo luận các thí nghiệm và phân tích kết quả theo các khía cạnh Hiệu năng (Performance), Phần thưởng (Reward), Suy luận cho việc chọn hành động (Reasoning for Action Selection). Sau đó, chúng tôi so sánh suy luận giữa một tác nhân RL và một tác nhân LLM.

Hiệu năng: Về hiệu năng LLM tổng quát, kết quả của chúng tôi cho thấy GPT-4o-mini có sự đánh đổi cân bằng hơn giữa thời gian chạy và phần thưởng. Trong Hình 4, chúng tôi thể hiện kết quả thí nghiệm 1LLM+4RL với nhiều mô hình. Trong số các mô hình được kiểm thử, o3-mini đạt phần thưởng cao nhất với thời gian thực thi chậm nhất, theo sau là mô hình lớn hơn o1-mini, vốn có thời gian thực thi tương tự. DeepSeek-V3 cho hiệu năng thấp nhất xét theo hàm thưởng của CAGE 4 nhưng nhanh hơn o1 và o3. Cuối cùng, GPT-4o-mini có thời gian thực thi nhanh nhất nhưng phần thưởng thấp.

Về thời gian chạy, chúng tôi so sánh các thí nghiệm trong đó tất cả tác nhân đều do RL điều khiển hoặc tất cả đều do LLM điều khiển. Chúng tôi không tính đến pha huấn luyện cho các tác nhân RL, cũng như việc thiết kế prompt (prompt engineering) cho mô tả nhiệm vụ và định dạng quan sát đối với các tác nhân LLM. Trung bình, các thí nghiệm của chúng tôi kéo dài 45,2 giây khi tất cả blue agent do RL điều khiển và 4704,6 giây khi tất cả chúng do LLM điều khiển với mô hình nhanh nhất mà chúng tôi kiểm thử (tức là GPT-4o-mini). Điều này có nghĩa là, không tính pha huấn luyện tốn thời gian cho tác nhân RL, các tác nhân do RL điều khiển nhanh hơn xấp xỉ **104,1 lần** so với các tác nhân do LLM điều khiển khi thực hiện việc chọn hành động.




Hình 5. Phần thưởng cho mỗi chiến lược red agent khi đối đầu với blue agent LLM và blue agent RL.

Phần thưởng: Hàm thưởng cho CAGE 4 là phần thưởng chung tích lũy (cumulative joint reward) cho các blue agent, dựa trên các hình phạt vì dịch vụ không khả dụng. Từ các thí nghiệm của chúng tôi với blue agent 1LLM+4RL (Hình 4), o3-mini nhận ít hình phạt nhất. GPT-4o-mini có phần thưởng thấp nhất trong các mô hình OpenAI, nhưng thời gian thực thi của nó nhanh nhất trong tất cả các mô hình được kiểm thử. Vì nó cân bằng nhất, chúng tôi so sánh GPT-4o-mini với các tác nhân mạng khác nhau và cách tiếp cận RL KEEP.

Đối với CAGE 4, cách tiếp cận RL KEEP vượt trội hơn cách tiếp cận toàn LLM với GPT-4o-mini. Hình 5 thể hiện giá trị phần thưởng với các tác nhân khác nhau khi không có người phòng thủ, khi tất cả do LLM điều khiển (GPT-4o-mini), và khi tất cả do RL điều khiển (KEEP). Dựa trên trung bình phần thưởng μ và độ lệch chuẩn σ , một đội phòng thủ TOÀN RL hoạt động tốt hơn trước các red agent đa dạng ($\mu = -493$, $\sigma = 95,9$) so với một đội TOÀN LLM ($\mu = -2547,2$, $\sigma = 498,8$). Chúng tôi thấy rằng sự đa dạng của red agent không ảnh hưởng đáng kể đến phần thưởng của tác nhân RL, trái ngược với đội tác nhân do LLM điều khiển, vốn hoạt động tốt hơn một chút trước một đối thủ (tức là StealthyFSM).

Định nghĩa hàm thưởng dựa trên các hình phạt về tính khả dụng và giả định kẻ tấn công luôn cố gắng từ chối dịch vụ đối với người dùng. Tuy nhiên, điều này không thực tế vì kẻ tấn công xâm phạm hệ thống mà không ảnh hưởng đến tính khả dụng [1]. Chẳng hạn, với red agent ImpactFSM, tác nhân LLM hoạt động kém hơn so với khi không có người phòng thủ nào, do mục tiêu của kẻ tấn công (tức là ưu tiên leo thang đặc quyền và gây tác động lên một vài máy chủ đã bị xâm phạm). Với kịch bản này, chúng tôi cho rằng hàm thưởng không phản ánh đúng mức an ninh của mạng, vì đối thủ có đặc quyền cao trên mạng.

Suy luận cho việc chọn hành động: Chúng tôi cũng muốn hiểu lý do đằng sau việc chọn hành động của tác nhân LLM. Cụ thể, chúng tôi so sánh việc chọn hành động của tác nhân RL và LLM trong các kịch bản tương tự. Trước tiên chúng tôi phân tích các thí nghiệm liên quan đến một LLM có phần thưởng và hiệu năng tốt nhất (1 LLM + 4 RL, o3-mini). Chúng tôi phân tích một episode gồm 500 bước và loại bỏ mẫu của



Hình 6. Phân cụm việc chọn hành động theo lý do (Action Selection Clustering by Reason).

bước khởi tạo.

Chúng tôi tạo ra các cụm (clusters) gồm những lý do tương tự gắn với hành động của chúng để phân tích một cách hệ thống. Chúng tôi dùng mô hình *text-embedding-3-large* của OpenAI để chuyển dữ liệu văn bản thành các embedding số, theo sau là chiến lược phân cụm K-Means tăng cường bằng PCA [27]. Do dữ liệu của chúng tôi có số chiều cao (499 mẫu, mỗi mẫu 3072 đặc trưng), các phương pháp DBSCAN [28] không tối ưu cho phân tích của chúng tôi, nên chúng tôi dùng Phương pháp khuỷu tay (Elbow Method) [29] và Điểm Silhouette (Silhouette Score) [30] và xác định $K = 4$ là số cụm tối ưu. Việc áp dụng PCA [31] giúp chúng tôi giảm số chiều xuống ba thành phần, tạo thuận lợi cho việc trực quan hóa và khả năng diễn giải. Hình 6 thể hiện các cụm được tạo ra.

Các cụm và điểm dữ liệu (DP — data points) gắn với 499 mẫu được mô tả trong Bảng IV. Chúng tôi cấu trúc các cặp hành động–lý do trong mỗi cụm theo định dạng từ điển, rồi dùng GPT-4o để tóm tắt mỗi cụm và yêu cầu mô hình “Tóm tắt chủ đề chính của cụm liên quan đến an ninh sau đây trong một câu”. Chúng tôi cũng phân tích thủ công mỗi cụm để cung cấp một mô tả tùy chỉnh cho từng cụm.

Từ góc độ an ninh, lý do chọn hành động cho mỗi cụm cho thấy một chiến lược phòng thủ có cấu trúc của tác nhân do LLM điều khiển. Cluster 0 cho thấy một cách tiếp cận phòng thủ chủ động (proactive) bằng cách thực hiện các hành động phân tích và đánh lừa (deception) khi không có hoạt động đáng ngờ nào được phát hiện và tác nhân đang rảnh. Cluster 1 tập trung vào các hành động sau khi nhận cảnh báo và chủ động cố gắng loại bỏ các tiến trình độc hại nếu một tác nhân khác thông báo về hoạt động độc hại. Cluster 2 cho thấy tác nhân cố gắng hiểu nguyên nhân thất bại do một hành động trước đó gây ra bằng cách phân tích nó. Cluster 3 tóm tắt các nỗ lực của tác nhân nhằm đảm bảo việc triển khai đúng các kỹ thuật.


So sánh việc chọn hành động giữa RL và LLM: Chúng tôi so sánh quá trình chọn hành động cho một tác nhân do LLM điều khiển có phần thưởng tốt nhất (o3-mini) với một

Bảng IV
SO SÁNH CÁC BẢN TÓM TẮT CỦA GPT-4O VỚI CÁC BẢN TÓM TẮT THỦ CÔNG.

Cluster	Tóm tắt bởi GPT-4o	Tóm tắt thủ công
Cluster 0 (202 DP)	Khuyến nghị chủ động triển khai mỗi nhử (decoy) ở nhiều vùng mạng như một biện pháp phòng ngừa để sớm nhận diện và dự hoạt động đồ tiềm ẩn, đảm bảo phát hiện mà không ảnh hưởng tính khả dụng dịch vụ giữa lúc đang phân tích và không có hoạt động đáng ngờ hiện tại.	<i>DeployDecoy</i> như một biện pháp phòng ngừa và chạy <i>Analyse</i> để phát hiện hoạt động độc hại khi không quan sát thấy cảnh báo.
Cluster 1 (103 DP)	Chủ đề chính là nhu cầu phân tích thêm các kết nối đáng ngờ mức INFO lặp lại trên nhiều máy chủ và máy chủ dịch vụ trong mạng để xác định sự hiện diện và mức độ của hoạt động “đỏ” hoặc xâm phạm tiềm ẩn.	<i>Analyse</i> và <i>DeployDecoy</i> khi nhận thấy các kết nối mức INFO tái diễn; <i>Remove</i> như biện pháp phòng ngừa khi blue agent khác thông báo hoạt động độc hại.
Cluster 2 (93 DP)	Chủ đề chính là nhiều lần triển khai mỗi nhử thất bại trong mạng văn phòng cho thấy các vấn đề cấu hình tiềm ẩn hoặc mối đe dọa chưa bị phát hiện, đòi hỏi phân tích thêm và thử lại để đảm bảo phát hiện vững chắc và cảnh báo sớm bất kỳ hoạt động đồ nào.	Các nỗ lực chạy <i>DeployDecoy</i> hoặc <i>Analyse</i> đã thất bại. Chạy <i>Analyse</i> để phát hiện vấn đề cấu hình hoặc hoạt động độc hại gây ra thất bại.
Cluster 3 (101 DP)	Chủ đề chính là hiểu tầm quan trọng của việc giám sát và phân tích liên tục các đợt triển khai mỗi nhử đang diễn ra để đảm bảo chúng được thiết lập đúng và hiệu quả trong việc phát hiện sớm hoạt động của red agent, đồng thời duy trì an ninh và tính toàn vẹn hệ thống.	Hành động <i>DeployDecoy</i> đang diễn ra; sau đó, chạy <i>Analyse</i> để xác nhận mỗi nhử được triển khai đúng và phát hiện hoạt động đồ sớm.

tác nhân do RL điều khiển kiểu KEEP, đối đầu với kẻ tấn công CAGE 4 mặc định. Hình 7 thể hiện bản tóm tắt việc chọn hành động cho một episode của mỗi tác nhân trong một kịch bản tương tự.

Tác nhân RL KEEP tuân theo một chiến lược ra quyết định thụ động (passive), dựa nhiều vào các hành động Monitor,



Hình 7. So sánh số đếm hành động (Action Count) cho tác nhân RL và LLM.

Sleep và Remove. Nó thường xuyên chuyển sang trạng thái Sleep, với xác suất cao quay lại trạng thái này từ gần như mọi hành động khác. Khi phản ứng trước các mối đe dọa tiềm ẩn, tác nhân ưu tiên phân tích các máy chủ để tìm hoạt động đáng ngờ trước khi cam kết hành động. Các hành động như Restore và BlockZoneTraffic dường như là các biện pháp cuối cùng (last-resort), có lẽ do tác động đáng kể của chúng lên tính khả dụng. Bằng cách tránh các can thiệp hung hãn trừ khi cần thiết, tác nhân đảm bảo luồng lưu lượng mạng trôi chảy và ngăn ngừa gián đoạn.

Mặt khác, tác nhân LLM tuân theo một cách tiếp cận đánh lừa và phân tích, ưu tiên việc triển khai mỗi nhữ trong khi tránh các hành động Restore. Sau khi phân tích nhật ký suy luận (reasoning log), chúng tôi nhận thấy tác nhân do LLM điều khiển quyết định dùng Remove và BlockTrafficZone khi các tác nhân khác thông báo về một khả năng xâm phạm thông qua vectơ truyền thông của chúng. Trong những tình huống mà một xâm phạm cấp người dùng được phát hiện ở nơi khác trong mạng, tác nhân ưu tiên các hành động ít gây gián đoạn hơn như DeployDecoy hoặc Analyse thay vì BlockTrafficZone. Tác nhân tránh thực thi hành động Restore, có thể vì nó có thể gây vấn đề về tính khả dụng cho người dùng green. Phân tích của chúng tôi cho thấy trong một số trường hợp, lý do chọn hành động dễ bị ảo giác (hallucination); chúng tôi thấy nhiều trường hợp tác nhân diễn giải sai vectơ truyền thông của một tác nhân (tức là giả định nó từ agent 4 trong khi thực ra từ agent 3) hoặc thay đổi định nghĩa của hành động.

Ở đây, chúng tôi mô tả một số giả thuyết của mình nhằm biện giải cho sự khác biệt về kết quả chọn hành động giữa tác nhân RL và LLM:

- Theo tài liệu CAGE 4 [13], hành động Monitor được chạy tự động mỗi lượt, và việc gọi nó không có tác dụng. Do đó, dù tác nhân RL có chọn nó, chúng tôi không định nghĩa nó như một tùy chọn trong prompt.
- Để giữ tác nhân hoạt động, chúng tôi không định nghĩa hành động Sleep trong prompt. Việc đưa định nghĩa Sleep và các trường hợp dùng nó khi tác nhân bận có thể cải thiện hiệu năng của tác nhân LLM khi các hành động đang diễn ra.

- Định nghĩa của chúng tôi về Restore và BlockTrafficZone có thể đã khiến LLM tránh chúng để bảo toàn tính khả dụng. Chúng tôi đã mô tả cách các hành động này có thể gây gián đoạn dịch vụ người dùng. Do đó, điều chỉnh định nghĩa của các hành động có thể làm giảm các hình phạt về tính khả dụng.
- Để đánh giá năng lực suy luận vốn có của LLM cho ACD, prompt của chúng tôi không bao gồm một chiến lược với các quy tắc quyết định hành động tường minh, cũng không có hướng dẫn riêng theo tình huống. Chúng tôi có thể cải thiện hiệu năng của tác nhân ACD dùng LLM bằng hướng dẫn dựa trên suy luận của RL.

Như chúng ta thấy, cả hai chiến lược đều phản ánh suy luận an ninh. Dù nhận nhiều hình phạt hơn tác nhân RL, chúng tôi thấy rằng tác nhân blue do LLM điều khiển có thể truyền thông hiệu quả với các tác nhân RL khác, phân tích cú pháp quan sát của chúng, và suy luận từ góc độ an ninh mà không cần bất kỳ huấn luyện trước nào, ngoài ngữ cảnh được cung cấp trong prompt của nó.

V. THẢO LUẬN

Giờ chúng tôi thảo luận một số hạn chế của LLM khi tương tác trong các môi trường đa tác nhân với các ACD khác, và bàn về những hướng khả dĩ để giải quyết chúng.

Tính tương thích môi trường (Environment Compatibility): Môi trường CAGE 4 được thiết kế cho huấn luyện RL. Nhìn chung, sẽ không công bằng khi yêu cầu một LLM đa dụng (general purpose) chọn một hành động mà không có ngữ cảnh mà một cách tiếp cận được huấn luyện bằng RL sẽ có. Chúng tôi đang tổng hợp các quan sát số chiều cao của một người phòng thủ RL để một LLM suy luận về chúng, nên một LLM sẽ không quan sát và diễn giải tác động của các quyết định của nó tốt như một tác nhân do RL điều khiển. Hơn nữa, chúng tôi đang điều kiện hóa sự thành công của tác nhân LLM theo hàm thưởng được thiết kế cho gym.

Ảo giác (Hallucinations): Dù đã mô tả các quy tắc mô phỏng trong prompt, các tác nhân LLM dễ bị ảo giác, bao gồm việc đọc sai các quan sát vectơ truyền thông, các mức xâm phạm, và các sự kiện an ninh. Việc tăng thời gian suy luận và tinh chỉnh (fine-tuning) các mô hình có thể giải quyết vấn đề này, kèm theo một sự sụt giảm hiệu suất cho việc chọn hành động. Suy luận của LLM có thể cải thiện nhanh với các chiến lược prompting phụ thuộc ngữ cảnh như Suy luận tương tự (Analogical Reasoning) [32]. Tuy vậy, nó vẫn có thể dễ bị ảo giác khi mô hình chưa được huấn luyện với các ví dụ mẫu (exemplars) liên quan theo ngữ cảnh.

Định nghĩa Prompt (Prompt Definition): Vì mục tiêu của chúng tôi là cung cấp cho tác nhân một ngữ cảnh thực tế, chúng tôi thiết kế prompt mà không nêu rõ chính sách phần thưởng hay cung cấp các giá trị phần thưởng cho LLM. Việc điều chỉnh prompt bằng cách mô tả hàm thưởng mà mô phỏng dùng và thêm ngữ cảnh về các ràng buộc mô phỏng (ví dụ: các bước thực thi hành động, phần thưởng trên mỗi bước/episode, chiến lược của red agent) sẽ làm tăng phần thưởng kỳ vọng. Tuy vậy, nó sẽ ảnh hưởng đến tính thực tế trong suy luận của

tác nhân cho các kịch bản an ninh thực. Prompt có thể được cải thiện để mô tả mỗi hành động chi tiết hơn nhằm tránh nhầm lẫn, như những trường hợp được nhận diện trong các cụm lý do 2 và 3. Tuy nhiên, việc tăng độ dài prompt cũng sẽ làm tăng tiêu thụ token.

VI. KẾT LUẬN

Chúng tôi tích hợp một cách tiếp cận mới để đưa suy luận LLM vào các tác nhân phòng thủ cho CAGE 4 của CybORG, một môi trường ACD đa tác nhân thực tế dựa trên RL. Chúng tôi đánh giá chúng trước các chiến lược red agent đa dạng và so sánh suy luận phòng thủ của LLM với RL đã huấn luyện trước trong các kịch bản khác nhau. Các thí nghiệm của chúng tôi cho thấy các tác nhân ACD dùng LLM có thể truyền thông hiệu quả khi chúng chia sẻ một giao thức truyền thông chung. Cùng nhau, chúng có thể bảo vệ một mạng với suy luận an ninh tương tự một đội người vận hành an ninh.

Bất chấp các hạn chế của LLM đã thảo luận, chúng tôi tin rằng các ACD gym sẽ hưởng lợi từ suy luận LLM cho người phòng thủ nhằm thu hẹp khoảng cách thực tế (reality gap) của chúng về khả năng chuyển giao và khả năng giải thích. LLM cũng có thể tạo điều kiện thay đổi các chiến lược phòng thủ mà không cần huấn luyện lại, thông qua việc tinh chỉnh prompt (prompt tuning). Người phòng thủ có thể hưởng lợi từ việc tích hợp LLM vào các ACD gym dùng RL để huấn luyện suy luận an ninh của các tác nhân ACD thực tế mà không có rủi ro khi triển khai chúng trên mạng thật. Hiện thực LLM của chúng tôi cho CybORG tạo thuận lợi cho việc chuyển giao các chính sách tối ưu sang các môi trường ACD khác và môi trường thực. Điều này có thể được thực hiện thông qua việc tinh chỉnh prompt để tái tạo các chính sách RL tối ưu đã huấn luyện trước.

LỜI CẢM ƠN

Công trình này được hỗ trợ một phần bởi Văn phòng Nghiên cứu Khoa học của Không quân (Air Force Office of Scientific Research) theo số tài trợ FA9550-24-1-0015, và bởi Trung tâm Quốc gia về An ninh mạng và Khả năng phục hồi Giao thông (TraCR) theo Tài trợ USDOT #69A3552344812. Cho nghiên cứu này, chúng tôi cũng hợp tác với OpenAI thông qua chương trình Cybergrant, sử dụng tín dụng API và kinh phí của họ để thúc đẩy nghiên cứu của chúng tôi về các giải pháp an ninh mạng dựa trên AI.

TÀI LIỆU

- [1] CheckPoint, “A Closer Look at Q3 2024: 75% Surge in Cyber Attacks Worldwide,” 2024. [Online]. Available: <https://blog.checkpoint.com/research/a-closer-look-at-q3-2024-75-surge-in-cyber-attacks-worldwide/>
- [2] S. R. Castro and A. A. Cárdenas, “Ghost in the SAM: Stealthy, robust, and privileged persistence through invisible accounts,” in *Proc. 2024 Workshop on Research on Offensive and Defensive Techniques in the Context of MATE Attacks (CheckMATE '24)*, ACM, 2024, pp. 59–72. <https://doi.org/10.1145/3689934.3690839>
- [3] M. Wolk et al., “Beyond cage: Investigating generalization of learned autonomous network defense policies,” 2022. <https://arxiv.org/abs/2211.15557>
- [4] M. Standen, M. Lucas, D. Bowman, T. J. Richer, J. Kim, and D. Marriott, “CybORG: A Gym for the Development of Autonomous Cyber Agents,” Aug. 2021.
- [5] A. Kott, “Autonomous intelligent cyber-defense agent: Introduction and overview,” 2023. <https://arxiv.org/abs/2304.12408>
- [6] P. Theron, “Alternative architectural approaches,” in *Autonomous Intelligent Cyber Defense Agent (AICA): A Comprehensive Guide*, A. Kott, Ed. Springer, 2023, vol. 87, pp. 17–46.
- [7] J. Loevenich, E. Adler, T. Huerten, and R. Rigolin Ferreira Lopes, “Design and evaluation of an autonomous cyber defence agent using DRL and an augmented LLM,” 2024. SSRN: <https://ssrn.com/abstract=5076836>
- [8] G. Palmer, C. Parry, D. J. B. Harrold, and C. Willis, “Deep reinforcement learning for autonomous cyber defence: A survey,” 2024. <https://arxiv.org/abs/2310.07745>
- [9] A. Lohn, A. Knack, A. Burke, and K. Jackson, “Autonomous cyber defence: a roadmap from lab to ops,” Center for Emerging Technology and Security, 2023.
- [10] C. Seifert et al., “CyberBattleSim,” <https://github.com/microsoft/cyberbattlesim>, 2021.
- [11] J. Janisch, T. Pevný, and V. Lisý, “NASimEmu: Network attack simulator & emulator for training agents generalizing to novel scenarios,” in *Computer Security. ESORICS 2023 Int. Workshops*, Part II, Springer, 2024, pp. 589–608. https://doi.org/10.1007/978-3-031-54129-2_35
- [12] A. Molina-Markham, C. Miniter, B. Powell, and A. Ridley, “Network environment design for autonomous cyberdefense,” <https://arxiv.org/abs/2103.07583>, 2021.
- [13] TTCP Working Group, “TTCP CAGE Challenge 4,” <https://github.com/cage-challenge/cage-challenge-4>, 2023.
- [14] A. V. Singh, E. Rathbun, E. Graham, L. Oakley, S. Boboila, A. Oprea, and P. Chin, “Hierarchical Multi-agent Reinforcement Learning for Cyber Network Defense,” <https://arxiv.org/abs/2410.17351>, Oct. 2024.
- [15] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *CoRR*, vol. abs/1707.06347, 2017. <http://arxiv.org/abs/1707.06347>
- [16] Cybermonics, “KEEP: A GNN-based PPO Model for MARL,” 2025. <https://github.com/cybermonics/cage-4-submission>
- [17] M. Rigaki, O. Lukáš, C. Catania, and S. Garcia, “Out of the cage: How stochastic parrots win in cyber security environments,” in *Proc. 16th Int. Conf. on Agents and Artificial Intelligence*, SCITEPRESS, 2024, pp. 774–781. <http://dx.doi.org/10.5220/0012391800003636>
- [18] Y. Yan, Y. Zhang, and K. Huang, “Depending on yourself when you should: Mentoring LLM with RL agents to become the master in cybersecurity games,” 2024. <https://arxiv.org/abs/2403.17674>
- [19] OpenAI, “OpenAI Models and Research,” 2024. <https://openai.com>
- [20] T. Brown et al., “Language Models are Few-Shot Learners,” in *Advances in Neural Information Processing Systems*, vol. 33, Curran Associates, 2020, pp. 1877–1901.
- [21] A. Kong et al., “Better Zero-Shot Reasoning with Role-Play Prompting,” in *Proc. 2024 Conf. NAACL: HLT (Vol. 1)*, ACL, 2024, pp. 4099–4113.
- [22] DeepSeek, “DeepSeek: Advanced AI Language Models and Enterprise Solutions,” 2025. <https://deepseek.ai>
- [23] Meta AI, “LLaMA: Open and Efficient Foundation Language Models,” 2023. <https://ai.meta.com/llama>
- [24] OpenRouter, Inc., “OpenRouter: A Unified Interface for Large Language Models,” 2025. <https://openrouter.ai>
- [25] Hugging Face, “Hugging Face: Democratizing Machine Learning,” 2024. <https://huggingface.co>
- [26] Weights & Biases, “Weights & Biases: Machine Learning Experiment Tracking,” 2025. <https://wandb.ai/site/>

- [27] P. Berkhin, “K-means clustering,” in *Encyclopedia of Machine Learning*, Springer, 2011, pp. 563–564.
- [28] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, “A density-based algorithm for discovering clusters in large spatial databases with noise,” in *Proc. KDD’96*, AAAI Press, 1996, pp. 226–231.
- [29] H. Humaira and R. Rasyidah, “Determining the appropriate cluster number using elbow method for k-means algorithm,” in *Proc. 2nd Workshop on Multidisciplinary and Applications (WMA)*, 2020, pp. 1–8.
- [30] P. J. Rousseeuw, “Silhouettes: A graphical aid to the interpretation and validation of cluster analysis,” *J. Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.
- [31] W. J. Weber and J. C. Morris, “Kinetic models of sorption processes,” *J. Sanitary Engineering Division*, vol. 89, no. 2, pp. 31–60, 1963.
- [32] M. Yasunaga et al., “Large Language Models as Analogical Reasoners,” <https://arxiv.org/abs/2310.01714>, Mar. 2024.